

4 月机器学习算法班：矩阵分析与应用(4月终稿)

程博士

julyedu.com

1 序言

2 线性代数基本知识(新视角)

3 特征分解(凸优化中的重要技术)

4 Singular Value Decomposition(SVD)分解与应用(万能矩阵分解)

本次课件主要参考书目

- ① 本人矩阵理论学习笔记
- ② 张贤达，矩阵分析与应用
- ③ Gilbert Strang, Introduction to Linear Algebra, 英文原版
- ④ Roger A. Horn, Matrix Analysis, 英文原版
- ⑤ Gene H. Golub and Charles F. Van Loan, Matrix Computations, 英文原版

向2-5的原著作者致谢！

部分使用的数学符号表

\mathbb{R}^n	n 维实空间
$\mathbb{R}^{m \times n}$	$m \times n$ 的实矩阵集合
T	转置
$\det(\mathbf{A})$	行列式
$C(\mathbf{A})$	列空间
$N(\mathbf{A})$	零空间
\mathbf{A}^{-1}	逆
$\text{diag}(\mathbf{a})$	将向量转化为对角矩阵
Tr	迹(trace)
rank	秩

示例表

红色框表示非常重要的定理或内容

定理或内容，仔细弄明白

绿色框表示具体的例子

举例，会举一反三

- 1 序言
- 2 线性代数基本知识(新视角)
- 3 特征分解(凸优化中的重要技术)
- 4 Singular Value Decomposition(SVD)分解与应用(万能矩阵分解)

重新看待矩阵和 $\mathbf{Ax} = \mathbf{b}$

- 矩阵绝不是把一堆数用括号括起来！本课件中，假设 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 。



$$\underbrace{\begin{bmatrix} 2 & -1 \\ 1 & 1 \end{bmatrix}}_{\mathbf{A} \in \mathbb{R}^{2 \times 2}} \underbrace{\begin{bmatrix} x \\ y \end{bmatrix}}_{\mathbf{x} \in \mathbb{R}^2} = \underbrace{\begin{bmatrix} 1 \\ 5 \end{bmatrix}}_{\mathbf{b} \in \mathbb{R}^2} \quad (1)$$

$$\underbrace{\begin{bmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{bmatrix}}_{\mathbf{A} \in \mathbb{R}^{3 \times 3}} \underbrace{\begin{bmatrix} u \\ v \\ w \end{bmatrix}}_{\mathbf{x} \in \mathbb{R}^3} = \underbrace{\begin{bmatrix} 5 \\ -2 \\ 9 \end{bmatrix}}_{\mathbf{b} \in \mathbb{R}^3} \quad (2)$$

$\mathbf{Ax} = \mathbf{b}$ 的行视图

- 行视图—凸优化中的超平面

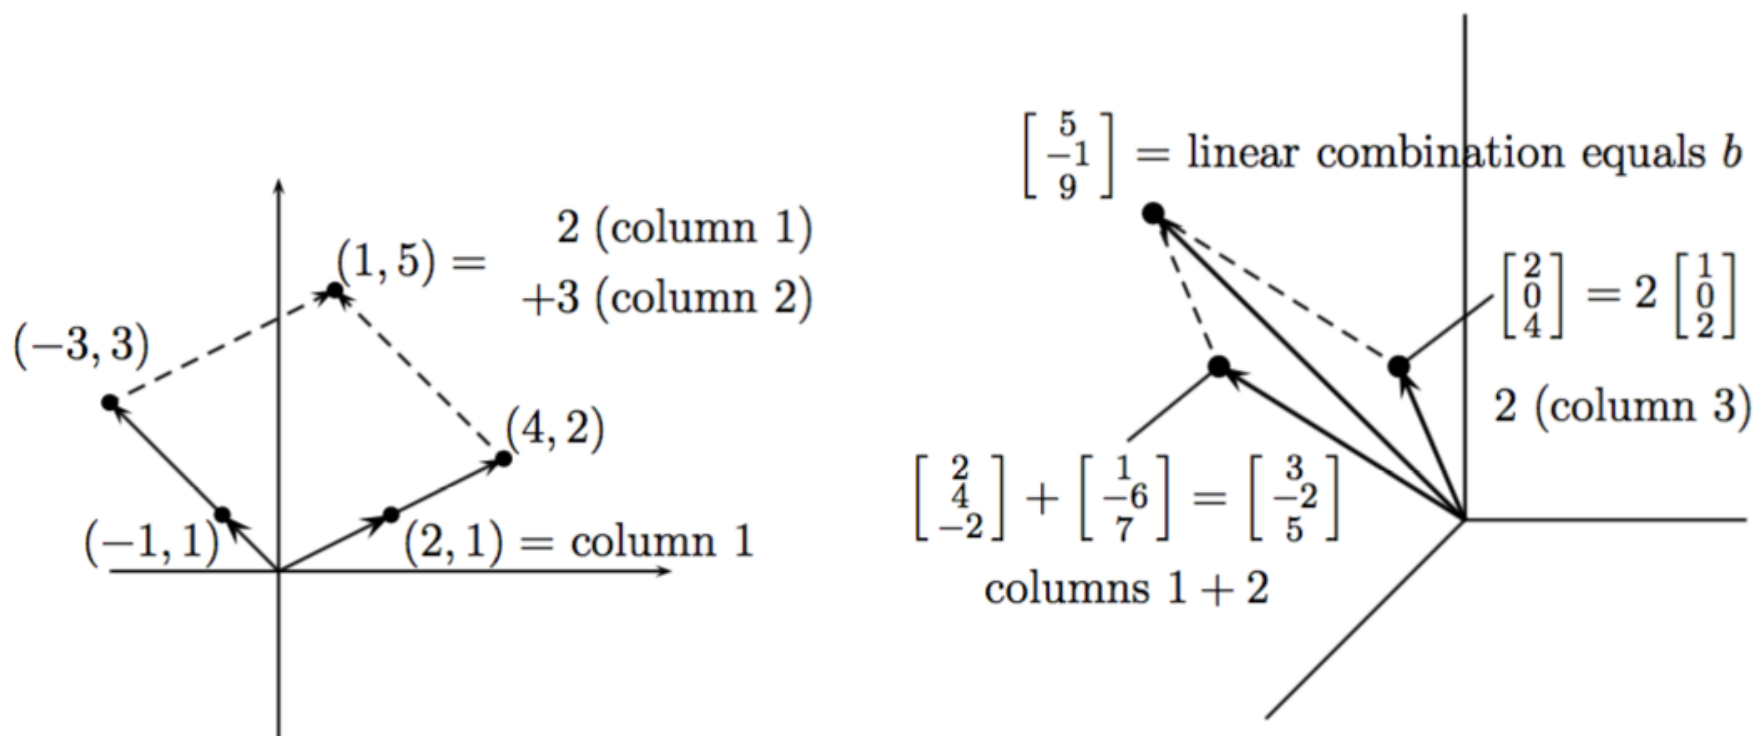
$$\begin{aligned} 2x - y &= 1 \\ x + y &= 5 \end{aligned} \quad (3)$$



$\mathbf{Ax} = \mathbf{b}$ 的列视图

- 列视图—矩阵列的线性组合。思考：所有的线性组合是？

$$x \begin{bmatrix} 2 \\ 1 \end{bmatrix} + y \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 5 \end{bmatrix} \quad (4)$$



线性相关和线性无关

- 线性相关(Linear dependence): 矢量集 $[\mathbf{a}_1, \dots, \mathbf{a}_n]$ 是线性相关的, 如果 $\sum_{k=1}^n c_k \mathbf{a}_k = \mathbf{0}$, 当且仅当 $c_1, c_2, \dots, c_n \neq 0$ 。即, 至少有一个向量, \mathbf{a}_l 可以由其它向量线性表出:

$$\mathbf{a}_l = -\frac{1}{c_l} \sum_{k=1, k \neq l}^n c_k \mathbf{a}_k \quad (5)$$

- 线性无关(Linear independence): 矢量集 $[\mathbf{a}_1, \dots, \mathbf{a}_n]$ 是线性无关的(即不是线性相关的), 如果 $\sum_{k=1}^n c_k \mathbf{a}_k = \mathbf{0}$, 当且仅当 $c_1, c_2, \dots, c_n = 0$
- 定义 $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_n]$, 则 $\mathbf{A}\mathbf{x} = \mathbf{0}$ 只有 $\mathbf{x} = \mathbf{0}$, 没有其它的线性组合能产生 $\mathbf{0}$ 。此时矩阵 \mathbf{A} 可逆。

线性相关和线性无关(举例)

举例

● $\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3] = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 3 & -1 \\ 0 & 0 & 1 \end{bmatrix}$ 线性无关, why?

● $\mathbf{B} = [\mathbf{b}_1, \mathbf{b}_2, \mathbf{b}_3] = \begin{bmatrix} 1 & 2 & -3 \\ 0 & 3 & -3 \\ 1 & 1 & -2 \end{bmatrix}$ 线性相关, why?

Span、基和子空间(Subspace)

- Span:

$$\text{span}[\mathbf{a}_1, \dots, \mathbf{a}_n] = \left\{ \mathbf{y} \in \mathbb{R}^m \mid \mathbf{y} = \sum_{k=1}^n c_k \mathbf{a}_k \right\} = S$$

- ▶ $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_n]$ 的所有线性组合。此时，如果 $[\mathbf{a}_1, \dots, \mathbf{a}_n]$ 线性无关的，则它们是 S 的一组基(basis)。正交基是指 $\mathbf{a}_i^T \mathbf{a}_j = \mathbf{0}$ 。
- ▶ S 可以有不同的一组基，但是基里向量的个数是相同的，被称为 S 的维数(dimension)，等于 $\text{rank}(\mathbf{A})$ 。一个子空间用一组基就可以表示了！


$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 3 & 3 \\ 0 & 0 & 0 \end{bmatrix}, S = \text{span} \left[\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 2 \\ 3 \\ 0 \end{bmatrix} \right], \text{ 思考还有其它基吗?}$$

四个基本的子空间(1)

① 列空间(Column space) (值域、Span) : $C(\mathbf{A})$ 是 \mathbb{R}^m (not \mathbb{R}^n) 的子空间

► 定义: 包含所有列的线性组合, 即 $C(\mathbf{A}) = \{\mathbf{y} = \mathbf{A}\mathbf{x}, \mathbf{x} \in \mathbb{R}^n\}$

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 4 & 3 \\ 2 & 3 \end{bmatrix}, C(\mathbf{A}) = \text{span} \left[\begin{bmatrix} 1 \\ 4 \\ 2 \end{bmatrix}, \begin{bmatrix} 0 \\ 3 \\ 3 \end{bmatrix} \right], \text{ 构成了一个 } \mathbf{R}^3 \text{ 的子空间}$$



$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 4 & 3 \\ 2 & 3 \end{bmatrix}$$

$$\mathbf{b} = x_1 \begin{bmatrix} 1 \\ 4 \\ 2 \end{bmatrix} + x_2 \begin{bmatrix} 0 \\ 3 \\ 3 \end{bmatrix}$$

Plane = $C(\mathbf{A})$ = all vectors $\mathbf{A}\mathbf{x}$

四个基本的子空间(2)

- 零空间(Null space): $N(\mathbf{A})$ 是 \mathbf{R}^n (not \mathbf{R}^m) 的子空间
 - ▶ 定义: $N(\mathbf{A})$ 包含 $\mathbf{Ax} = \mathbf{0}$ 的所有的解的集合
 - ▶ 注意: $\mathbf{Ax} = \mathbf{b}$ 的解并不形成一个子空间

求 \mathbf{A} 的零空间的基

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 2 & 4 \\ 3 & 8 & 6 & 16 \end{bmatrix} \rightarrow \mathbf{U} = \begin{bmatrix} 1 & 2 & 2 & 4 \\ 0 & 2 & 0 & 4 \end{bmatrix}$$

$$\text{即 } \mathbf{Ux} = \mathbf{0}, \text{ 于是有 } s_1 = \begin{bmatrix} -2 \\ 0 \\ 1 \\ 0 \end{bmatrix} \quad s_2 = \begin{bmatrix} 0 \\ -2 \\ 0 \\ 1 \end{bmatrix}$$

$$\text{因此 } N(\mathbf{A}) = C \left(\begin{bmatrix} -2 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ -2 \\ 0 \\ 1 \end{bmatrix} \right), \text{ 是 } \mathbf{R}^4 \text{ 的子空间。}$$


四个基本的子空间(3-4)

- 行空间(Row space): $C(\mathbf{A}^T)$ 是 \mathbf{R}^n 的子空间
 - ▶ 定义: 包含所有行的线性组合

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 2 & 4 \\ 3 & 8 & 6 & 16 \end{bmatrix}, \text{ 则 } C(\mathbf{A}^T) = C\left(\begin{bmatrix} 1 \\ 2 \\ 2 \\ 4 \end{bmatrix}, \begin{bmatrix} 3 \\ 8 \\ 6 \\ 16 \end{bmatrix}\right)$$

- 左零空间(left null space): $N(\mathbf{A}^T) = \{\mathbf{A}^T \mathbf{y} = \mathbf{0}\}$ 的解集合, 是 \mathbf{R}^m 的子空间

四个基本的子空间的关系和特殊情况



利用子空间重新看待线性方程组的解

$\mathbf{Ax} = \mathbf{b}$ 方程的解


- 只有唯一解，则 $\mathbf{b} \in C(\mathbf{A})$ ， $N(\mathbf{A})$ 的维数是 0。
- 有无穷多个解， $\mathbf{b} \in C(\mathbf{A})$ ， $N(\mathbf{A})$ 的维数大于 0。
- 无解，则 $\mathbf{b} \notin C(\mathbf{A})$
- 如果有解，解的形式 $\mathbf{x} = \mathbf{p} + \mathbf{v}$

- 1 序言
- 2 线性代数基本知识(新视角)
- 3 特征分解(凸优化中的重要技术)**
- 4 Singular Value Decomposition(SVD)分解与应用(万能矩阵分解)

方阵的特征值(Eigenvalues)与特征向量(Eigenvectors)

$\mathbf{Ax} = \lambda \mathbf{x}$ 几何意义, 并思考如何计算 \mathbf{A}^{1000}

给定一个矩阵 $\mathbf{A} = \begin{bmatrix} 4 & 1 \\ 1 & 4 \end{bmatrix}$, 对于 $\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, 则有 $\mathbf{Ax}_1 = \begin{bmatrix} 4 \\ 1 \end{bmatrix}$; 对于 $\mathbf{x}_3 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$, 则有 $\mathbf{Ax}_3 = 5 \begin{bmatrix} 1 \\ 1 \end{bmatrix}$



特征分解的性质

特征分解的一般性质

- 对于 $\mathbf{A}\mathbf{x}_i = \lambda_i\mathbf{x}_i$ ，如果所有的特征值都不相同，则相应的所有的特征向量线性无关。此时， \mathbf{A} 可以被对角化为

$$\mathbf{A} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^{-1}. \quad (6)$$

其中 $\mathbf{V} = [\mathbf{x}_1, \dots, \mathbf{x}_n]$ ， $\mathbf{\Lambda} = \text{Diag}(\lambda_1, \dots, \lambda_n)$ 。思考 \mathbf{A}^{1000} 。

- 思考：所有的方阵都可以对角化吗？

对称矩阵的特征分解(1/2)

- 如果一个对称矩阵的特征值不同，则其相应的所有的特征向量正交($\mathbf{U}\mathbf{U}^T = \mathbf{U}^T\mathbf{U} = \mathbf{I}$)

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^T \quad (7)$$

$$= [\mathbf{u}_1, \dots, \mathbf{u}_n] \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} \begin{bmatrix} \mathbf{u}_1^T \\ \vdots \\ \mathbf{u}_n^T \end{bmatrix} \quad (8)$$

$$= \sum_{i=1}^n \lambda_i \mathbf{u}_i \mathbf{u}_i^T \quad (9)$$

对称矩阵的特征分解(2/2)

- 对称矩阵的特征值是实数
- 如果 $\mathbf{A} \in \mathbf{R}^{n \times n}$ 是一对称矩阵且 $\text{rank } r \leq n$, 则有

$$\underbrace{|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_r|}_r > \underbrace{\lambda_{r+1} = \dots \lambda_n}_n = 0 \quad (10)$$

- $\text{Rank}(\mathbf{A}^T \mathbf{A}) = \text{Rank}(\mathbf{A} \mathbf{A}^T) = \text{Rank}(\mathbf{A}) = \text{Rank}(\Lambda)$
- 思考对于任意矩阵, 能否找到一个类似的分解?

二次型(Quadratic Form)

- 给定矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$, 函数

$$\mathbf{x}^T \mathbf{A} \mathbf{x} = \sum \sum x_i x_j a_{ij} \quad (11)$$


被称为二次型。

- 如果对于所有 $\mathbf{x} \in \mathbb{R}^n$, 有 $\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0$, 则为半正定矩阵(positive semidefinite), 此时 $\lambda(\mathbf{A}) \geq 0$ 。
- 如果对于所有 $\mathbf{x} \in \mathbb{R}^n, \mathbf{x} \neq \mathbf{0}$, 有 $\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$, 则为正定矩阵(positive definite)。
- 负定矩阵
- 不定矩阵(indefinite)


二次型

二次型图形

- 二次函数 $f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x} + 2\mathbf{b}^T \mathbf{x} + c$
- $\nabla f(\mathbf{x}) = 2\mathbf{A}\mathbf{x} + 2\mathbf{b}$, $\nabla^2 f(\mathbf{x}) = 2\mathbf{A}$



(a) PSD \mathbf{A} .



(b) indefinite \mathbf{A} .

特征分解的应用—PCA本质讲述(1/3)

PCA的本质

- 给定一个矩阵 $\mathbf{X} \in \mathbb{R}^{m \times n}$ ，例如

$$\mathbf{X} = \begin{bmatrix} a_1 & a_2 & \cdots & a_n \\ b_1 & b_2 & \cdots & b_n \end{bmatrix}$$

选择 $k < m$ 个正交基进行降维的同时又尽量保留原始的信息。即，使得 \mathbf{A} 变换到这组基后，使得行向量间的协方差为0，而每个行向量的方差尽可能大。

- 协方差矩阵(对称半正定)为

$$\mathbf{C}_X = \frac{1}{n} \mathbf{X} \mathbf{X}^T = \begin{bmatrix} \frac{1}{n} \sum_{i=1}^n a_i^2 & \frac{1}{n} \sum_{i=1}^n a_i b_i \\ \frac{1}{n} \sum_{i=1}^n a_i b_i & \frac{1}{n} \sum_{i=1}^n b_i^2 \end{bmatrix}$$

特征分解的应用—PCA本质讲述(2/3)

PCA的本质

- 问题：假设变换矩阵为 $\mathbf{Y} = \mathbf{Q}\mathbf{X}$ ，并先假设 \mathbf{Q} 是方阵(先不降维)，则有

$$\mathbf{C}_Y = \frac{1}{n} \mathbf{Y}\mathbf{Y}^T = \mathbf{Q}\mathbf{C}_X\mathbf{Q}^T$$

如何使得 \mathbf{C}_Y 是一个对角矩阵？回忆 $\mathbf{C}_X = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^T \Rightarrow \mathbf{\Lambda} = \mathbf{U}^T\mathbf{C}_X\mathbf{U}$ 。如果 $\mathbf{Q} = \mathbf{U}^T$ ？

- 思考如何降维？

特征分解的应用—PCA本质讲述(3/3)

PCA降维举例

- ① $\mathbf{X} = \begin{bmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{bmatrix}$, $\mathbf{C}_X = \begin{bmatrix} \frac{6}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{6}{5} \end{bmatrix}$
- ② 计算 \mathbf{C}_X 特征值为: $\lambda_1 = 2$, $\lambda_2 = 2/5$, 特征值特征向量为 $\begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$, $\begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$, 可验证 $\Lambda = \mathbf{U}^T \mathbf{C}_X \mathbf{U}$
- ③ 降维: $\mathbf{Y} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \mathbf{X} = \begin{bmatrix} -\frac{3}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 & \frac{3}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$
- ④ 可验证此时 $\mathbf{C}_Y = \lambda_1$

- 1 序言
- 2 线性代数基本知识(新视角)
- 3 特征分解(凸优化中的重要技术)
- 4 Singular Value Decomposition(SVD)分解与应用(万能矩阵分解)

SVD分解：特征分解的广义化

任何秩为 r 的矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$ ，可以被分解为

$$\mathbf{A} = \underbrace{[\mathbf{U}_1 \mathbf{U}_2]}_{\mathbf{U}} \underbrace{\begin{bmatrix} \Sigma_1 & \mathbf{0}_{r \times (n-r)} \\ \mathbf{0}_{(m-r) \times r} & \mathbf{0}_{(m-r) \times (n-r)} \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} \mathbf{V}_1^T \\ \mathbf{V}_2^T \end{bmatrix}}_{\mathbf{V}^T} \quad (12)$$

$$= \mathbf{U} \Sigma \mathbf{V}^T \quad (13)$$

$$= \mathbf{U}_1 \Sigma_1 \mathbf{V}_1^T \quad (14)$$

$$= \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T \quad (15)$$

其中 $\mathbf{U} \in \mathbb{R}^{m \times m}$ 和 $\mathbf{V} \in \mathbb{R}^{n \times n}$ 是正交矩阵。 $\Sigma_1 = \text{diag}(\sigma_1, \dots, \sigma_r)$ 且有 $\sigma_r > 0$ 。

(13)便于分析，但并不计算有效；(14)计算有效，但有时不方便分析；(15)方便展开，用于低秩矩阵计算。

SVD和特征分解的关系(1/3)

- 已知 $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$, 可得

$$\mathbf{A}\mathbf{A}^T = \mathbf{U}\mathbf{\Sigma}\mathbf{\Sigma}^T\mathbf{U}^T = \mathbf{U}\mathbf{\Lambda}_L\mathbf{U}^T \quad (16)$$

$$\mathbf{\Lambda}_L = \begin{bmatrix} \mathbf{\Sigma}_1^2 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}$$

- 结论: \mathbf{U} 是 $\mathbf{A}\mathbf{A}^T$ 的特征向量, $\sigma_1, \dots, \sigma_r, 0 \dots 0$ 特征值, 即

$$\sigma_k = \sqrt{\lambda_k(\mathbf{A}\mathbf{A}^T)} = \sqrt{\lambda_k(\mathbf{A}^T\mathbf{A})}$$

- 思考: 正定矩阵的奇异值分解?

SVD和子空间的关系(1/3)

- 列空间: $C(\mathbf{A}) = \{\mathbf{y} | \mathbf{y} = \mathbf{A}\mathbf{x}\}$

$$\begin{aligned}\mathbf{A}\mathbf{x} &= [\mathbf{U}_1 \mathbf{U}_2] \begin{bmatrix} \Sigma_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{V}_1^T \\ \mathbf{V}_2^T \end{bmatrix} \mathbf{x} \\ &= [\mathbf{U}_1 \mathbf{U}_2] \begin{bmatrix} \Sigma_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{c}_1 \\ \mathbf{c}_2 \end{bmatrix} \\ &= [\mathbf{U}_1 \mathbf{U}_2] \begin{bmatrix} \Sigma_1 \mathbf{c}_1 \\ \mathbf{0} \end{bmatrix} \\ &= \mathbf{U}_1 (\Sigma_1 \mathbf{c}_1)\end{aligned}$$

- $C(\mathbf{A}) = C(\mathbf{U}_1)$

SVD和子空间的关系(2/3)


- 零空间: $N(\mathbf{A}) = \{\mathbf{x} \neq \mathbf{0} | \mathbf{A}\mathbf{x} = \mathbf{0}\}$
- 设 $\mathbf{x} = \mathbf{V}_2\mathbf{c}$

$$\begin{aligned}\mathbf{A}\mathbf{x} &= [\mathbf{U}_1 \mathbf{U}_2] \begin{bmatrix} \Sigma_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{0} \\ \mathbf{c} \end{bmatrix} \\ &= \mathbf{0}\end{aligned}$$

- \mathbf{V}_2 是 $N(\mathbf{A})$ 的正交基
- 思考: $\mathbf{A}\mathbf{x} = \mathbf{b}$ 的解?

SVD和子空间的关系(3/3)

- $C(\mathbf{A}^T) = C(\mathbf{V}_1)$
- $N(\mathbf{A}^T) = C(\mathbf{U}_2)$
- SVD提供了计算四个子空间正交基的一种快速方法



低秩矩阵近似(降维)

- 给定矩阵 $\mathbf{A} \in \mathbf{R}^{m \times n}$, 其秩为 r , 需找一个矩阵 $\mathbf{B} \in \mathbf{R}^{m \times n}$, 其秩为 $k < r$, 使其能够最接近 \mathbf{A} 。
- 若 $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$, 定义

$$\mathbf{A}_k = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T \quad (17)$$

则有

$$\min_{\text{Rank}(\mathbf{B})=k} \|\mathbf{A} - \mathbf{B}\|_2 = \|\mathbf{A} - \mathbf{A}_k\|_2 = \sigma_{k+1} \quad (18)$$

- 应用: Principal Component Analysis(PCA), 维数减少, 数据压缩等等

低秩矩阵近似应用—图像压缩(1/3)

- 给定一副图像, $256 \times 512 = 2^{17}$ 矩阵
- CT MR 需要图像压缩, 希望尽可能无损
- 傅里叶变换(jpeg), 小波(jpeg2000)。
- 考虑用低秩矩阵近似方式: 存储 $\{\boldsymbol{\sigma}_i, \mathbf{u}_i, \mathbf{v}_i\}_{i=1}^k$, $k=1$ 时, 压缩比大致是 $256 \times 512 / (256 + 512) = 170$

低秩矩阵近似应用—图像压缩(2/3)



1 10 80 PCA类似。

低秩矩阵近似应用—图像压缩(3/3)

Example

```
clear all; close all; clc;
a=imread('lena.jpg');
imshow(mat2gray(a))
[m n]=size(a); a=double(a); r=rank(a);
[s v d]=svd(a);
%re=s*v*d';
re=s(:,:)*v(:,1:1)*d(:,1:1)'; figure; imshow(mat2gray(re));
imwrite(mat2gray(re),'1.jpg')
re=s(:,:)*v(:,1:20)*d(:,1:20)'; figure; imshow(mat2gray(re));
imwrite(mat2gray(re),'2.jpg')
re=s(:,:)*v(:,1:80)*d(:,1:80)'; figure; imshow(mat2gray(re));
imwrite(mat2gray(re),'3.jpg')
```

本节课总结和复习(跟着我思考)

谢谢！恳请大家批评指正！